### Insper


# Análise de texto de fontes desestruturadas e Web

Aula 05


Maciel Calebe Vidal

### Interação com servidor

- Fazer uma requisição
- Obter um documento








### Páginas Web

Representação em uma linguagem



### Como páginas Web funcionam?

- HTML
  - HyperText Markup Language
- Tag
  - Negrito
    - Fiquei sabendo que a <b>Netflix faliu</b>!
  - Imagem
    - <img src="insper.png">
  - Parágrafo
    - Bem-vindos!!!

### Como páginas Web funcionam?

## Este é um exemplo de página Web!

Estamos utilizando HTML, que é uma linguagem de **Marcação** de *texto* 

#### Este é um cabeçalho nível 2


E este é um parágrafo.

Link para o Google

```
...<!DOCTYPE html> == $0
<html>
 ▶ <head>...</head>
 ▼ <body>
    <hl>Este é um exemplo de página Web!</hl>
      "Estamos utilizando HTML, que é uma linguagem de "
      <b>Marcacão</b>
      " de "
      <i>texto</i>
    <h2>Este é um cabecalho nível 2</h2>
    E este é um parágrafo.
      "Link para o "
      <a href="https://www.google.com">Google</a>
    </body>
</html>
```

### Web Crawling


- Spider ou bots
- Indexar



https://www.scraping-bot.io/wp-content/uploads/2020/03/Spider-Crawlerweb-shine.png


### Web Scraping

Raspagem de dados




### Web Scraping

Raspagem de dados



### Crawling vs Scraping



### Dúvidas?

Obrigado pela participação!